Analisi del rischio di insolvenza nelle aziende di costruzione

Matteo Sartini

Giulia Cevoli

Luca Fabbricatore

Nicholas Zoffoli

Selezione delle aziende e costruzione del dataset

- Le aziende analizzate sono state prese dal sito AIDA e appartengono alla **sezione F del codice ATECO**, ovvero il settore delle costruzioni. Inoltre, sono state considerate solo le **società di capitali**.
- Per ciascuna azienda sono stati selezionati **10 indici finanziari**, volti a valutare: **Solvibilità , Redditività** , **Struttura patrimoniale** , **Dimensione aziendale.**
- Nel caso delle **aziende fallite**, sono state considerate esclusivamente quelle che hanno registrato il **primo evento negativo** negli ultimi **5 anni**.

Selezione degli indici finanziari

- Relativamente alle aziende che compongono il nostro dataset sono stati selezionati i seguenti Indici finanziari :

- **X1 : ROA**
- **X2 : EBITDAMargin**
- **X3 : ROD**
- **X4 : CCN/tot.Attivo**
- **X5 : tot.Attivo/tot.Debiti**
- **X6 : tot.Debiti breve/tot.Attivo**
- **X7 : Indice Liquidità Generale**
- **X8 : Indice Indipendenza Finanziaria**
- **X9 : AC/tot.Debiti**
- **X10 : Rotazione CCN**

LEGENDA :

- Redditività
- Solidità patrimoniale
- Solvibilità
- Indice di rotazione

Distribuzione campione

Quantile	Macroarea	Categoria_Anni	Attiva	Fallita
1	Centro	Meno di 10 anni	8	8
1	Centro	Più di 10 anni	6	6
1	Isole	Meno di 10 anni	1	1
1	Isole	Più di 10 anni	1	1
1	Nord Est	Meno di 10 anni	2	2
1	Nord Est	Più di 10 anni	3	3
1	Nord Ovest	Meno di 10 anni	1	1
1	Nord Ovest	Più di 10 anni	5	5
1	Sud	Meno di 10 anni	5	5
1	Sud	Più di 10 anni	1	1
2	Centro	Meno di 10 anni	6	6
2	Centro	Più di 10 anni	5	5
2	Isole	Meno di 10 anni	2	2
2	Isole	Più di 10 anni	2	2
2	Nord Est	Meno di 10 anni	5	5
2	Nord Ovest	Meno di 10 anni	6	6
2	Nord Ovest	Più di 10 anni	8	8
2	Sud	Meno di 10 anni	1	1
2	Sud	Più di 10 anni	5	5

Quantile	Macroarea	Categoria_Anni	Attiva	Fallita
3	Centro	Meno di 10 anni	5	5
3	Centro	Più di 10 anni	7	7
3	Isole	Meno di 10 anni	1	1
3	Isole	Più di 10 anni	2	2
3	Nord Est	Meno di 10 anni	5	5
3	Nord Est	Più di 10 anni	6	6
3	Nord Ovest	Meno di 10 anni	5	5
3	Nord Ovest	Più di 10 anni	10	10
3	Sud	Meno di 10 anni	1	1
3	Sud	Più di 10 anni	7	7
4	Centro	Meno di 10 anni	3	3
4	Centro	Più di 10 anni	14	14
4	Isole	Meno di 10 anni	3	3
4	Isole	Più di 10 anni	6	6
4	Nord Est	Meno di 10 anni	4	4
4	Nord Est	Più di 10 anni	13	13
4	Nord Ovest	Meno di 10 anni	7	7
4	Nord Ovest	Più di 10 anni	21	21
4	Sud	Meno di 10 anni	2	2
4	Sud	Più di 10 anni	12	12

Scelta del dataset ottimale

Sono stati utilizzati due metodi per diminuire il numero delle variabili nel dataset:

a) **PCA (Analisi delle Componenti Principali)**: ha prodotto **5 componenti principali**, capaci di spiegare il **79% della variabilità** del dataset;

b) **Metodo Stepwise**: ha selezionato **6 variabili**, mantenendo quelle con maggiore rilevanza statistica.

Successivamente, abbiamo testato entrambi i dataset sui modelli di analisi. Dai risultati ottenuti è emerso che il dataset ottenuto con il **criterio stepwise** garantisce una maggiore capacità in termini di classificazione.

I modelli, poi, scelti per valutare il rischio di dissesto aziendale sono **l'analisi discriminante lineare, l'analisi discriminante logistica** e le **reti neurali.**

Procedura stepwise

- Dal dataset originario di 10 variabili si è quindi applicata una procedura stepwise per selezionare in modo iterativo le variabili piu significative (backward) secondo il criterio AIC finché l'inclusione/esclusione di ulteriori variabili non migliora più il modello.

```
Step:  AIC=296.01
Default ~ x1mod + x3mod + x4mod + x7mod + x8mod + x9mod

        Df Deviance    AIC
<none>       282.01 296.01
+ x5mod  1   281.16 297.16
+ x10    1   281.28 297.28
+ x2mod  1   281.44 297.44
+ x6mod  1   281.79 297.79
- x9mod  1   288.30 300.30
- x4mod  1   289.76 301.76
- x7mod  1   301.01 313.01
- x3mod  1   303.91 315.91
- x1mod  1   307.14 319.14
- x8mod  1   321.64 333.64

Call:  glm(formula = Default ~ x1mod + x3mod + x4mod + x7mod + x8mod +
    x9mod, family = binomial(logit), data = dataset)

Coefficients:
(Intercept)        x1mod        x3mod        x4mod        x7mod        x8mod
   0.647175    -0.119891    -0.467405    -0.024925     0.010681    -0.054697
      x9mod
  -0.008586
```

ANALISI DISCRIMINATE LINEARE

- Il primo modello applicato è l'analisi discriminate lineare, usando solo le 6 varibili che suggerisce la procedura stepwise, ovvero **x1, x3, x4, x7, x8, x9**. Essa produce i seguenti risultati :

ANALISI DISC. LINEARE		
	reference	
prediction	0	1
0	186	53
1	21	154

Indici rilevati :

- *Accuracy* = **0.82**
- *Sensitivity* = **0.74**
- *Specificity* = **0.89**

ANALISI DISCRIMINANTE LOGISTICA

- Dopo di che si è proceduto con l'analisi discriminate logistica, sempre utilizzando le medesime variabili. In questo caso si genera la seguente matrice di confusione :

ANALISI DISC. LOGISTICA		
	reference	
prediction	0	1
0	195	38
1	12	169

Indici rilevati :

- *Accuracy* = **0.87**
- *Sensitivity* = **0.81**
- *Specificity* = **0.94**

Analisi dei coefficienti

Ad lineare vs Ad logistica

```
Coefficients of linear discriminants:
            LD1
x1  -0.44886284
x3 -18.84860888
x4  -0.38978250
x7   0.08233793
x8   0.03514153
x9  -1.01691204
```

```
Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept)  0.647175   0.329773   1.962  0.04971 *
x1mod       -0.119891   0.021843  -5.489 4.05e-08 ***
x3mod       -0.467405   0.116437  -4.014 5.96e-05 ***
x4mod       -0.024925   0.008564  -2.910  0.00361 **
x7mod        0.010681   0.002716   3.932 8.42e-05 ***
x8mod       -0.054697   0.009767  -5.600 2.14e-08 ***
x9mod       -0.008586   0.003635  -2.362  0.01817 *
```

Nel contesto lineare le variabili x7,x8 che rappresentano rispettivamente **l'indice di liquidità generale** e **l'indice di indipendenza** finanziaria sono le uniche con segno errato; anch'esse come le altre vanno nella direzione opposta al fallimento e quindi dovrebbero essere con segno negativo.

Nel modello logistico, invece, solo la variabile x7 (**indice di liquidità generale**) risulta con un segno non corretto.

Rete neurale – 1 livello

- Il terzo, ed ultimo, modello applicato è la rete neurale su un "data_test" pari al 20% del dataset iniziale. Essa dal punto di vista teorico dovrebbe essere il modello migliore a livello di performance e corretta classificazione, ma si piazza, invece, nel mezzo tra analisi discriminante lineare e logistica. Le principali cause possono derivare dalla dimensione del dataset (considerato abbastanza piccolo) e configurazione non ottimale dei vari parametri.

RETE NEURALE - 1 LIVELLO		
	reference	
prediction	0	1
0	31	13
1	1	38

Indici rilevati :

- *Accuracy* = **0.83**
- *Sensitivity* = **0.75**
- *Specificity* = **0.97**

Analisi grafica dei modelli

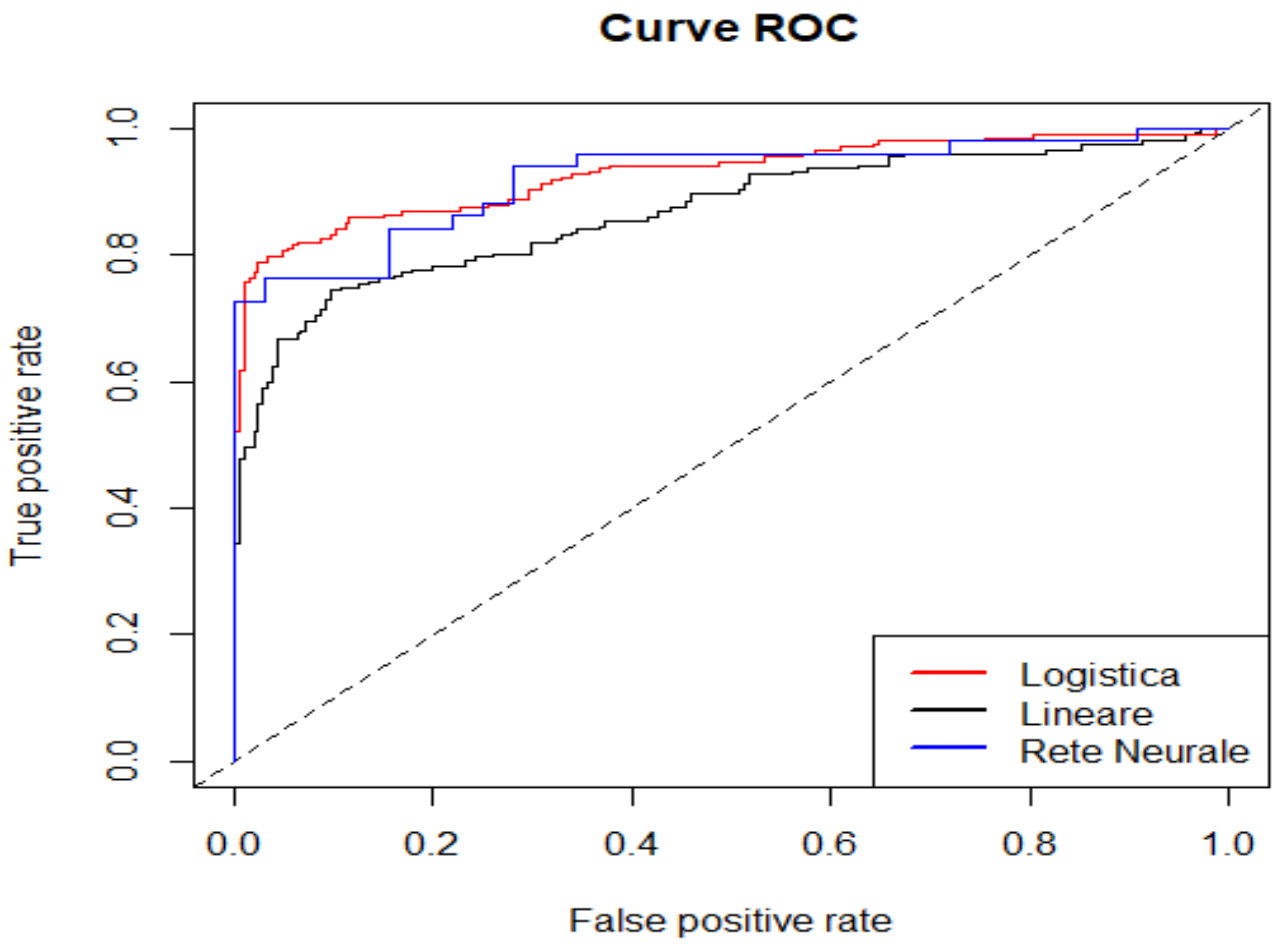

A livello grafico, tramite lo sviluppo, delle curve ROC viene visualizzato quanto detto in precedenza.

- AUC lineare = **0.86**
- AUC logistica = **0.93**
- AUC rete neurale = **0.92**

Rete neurale – 1 livello (PCA)

- Il modello basato su reti neurali è stato applicato anche ai dati ottimizzati tramite PCA. Questo modello ha raggiunto performance eccellenti, come evidenziato dagli indici rilevati.
  Questi risultati dimostrano che il modello è in grado di individuare in modo molto efficace sia le aziende fallite che quelle sane, confermando che la riduzione dimensionale tramite PCA ha migliorato la capacità predittiva della rete neurale, rendendola più bilanciata e affidabile.

RETE NEURALE - 1 LIVELLO		
	reference	
prediction	0	1
0	40	4
1	2	38

Indici rilevati :

- *Accuracy* = **0.93**
- *Sensitivity* = **0.90**
- *Specificity* = **0.95**

Analisi e confronto dei risultati

	STEPWISE			PCA		
	Lineare	Logistica	Rete Neurale	Lineare	Logistica	Rete Neurale
Accuracy	0,82	**0,87**	0,83	**0,85**	0,85	**0,93**
Sensitivity	0,74	**0,81**	0,74	**0,81**	0,78	**0,9**
Specificity	0,89	**0,94**	**0,96**	0,89	0,93	0,95